

PrivacIA: Um Framework de Anonimização com Validação Adversarial por LLM Local e Conformidade Formal à LGPD

v2.0 — 22/06/2026

Resumo

Nenhum framework existente na literatura combina anonimização automatizada de dados pessoais com validação adversarial por LLM local e mapeamento formal de conformidade à LGPD. Este artigo propõe o PrivacIA, um framework que integra essa contribuição tríplice até então isolada na literatura: (1) um pipeline de anonimização contextual combinando NER e regex para dados pessoais em português brasileiro; (2) validação adversarial automatizada por LLM local, que testa a robustez da anonimização contra ataques de re-identificação sem expor dados a APIs externas; e (3) mapeamento formal de 17 requisitos técnicos aos artigos específicos da LGPD, criando rastreabilidade jurídica verificável. O framework implementa um pipeline de quatro estágios — detecção, classificação, substituição e validação — otimizado para documentos em português brasileiro nos domínios jurídico, médico e financeiro. Apresentamos uma metodologia de avaliação adversarial abrangendo dez categorias de ameaças, incluindo correlação entre documentos, ataques de re-identificação temporal e desanonimização em larga escala por agentes LLM — cenário em que pesquisas recentes demonstram taxas de reconstrução de identidade de 68% com 90% de precisão [50]. Propomos um desenho experimental formal com comparações de baseline contra Presidio, Google DLP, Anonymous-by-Construction, LLM-Anonymizer e o framework adversarial Look Twice [51]. Resultados de avaliação preliminar em documentos jurídicos brasileiros demonstram recall de detecção de PII acima de 95% para entidades estruturadas e acima de 85% para entidades não-estruturadas, com degradação inferior a 10% na qualidade das respostas da IA.

Palavras-chave — LGPD, GDPR, Anonimização, Pseudonimização, Inteligência Artificial, LLM, Dados Pessoais, NER, PII, Proteção de Dados, IA Preservadora de Privacidade, Análise Adversarial, Português Brasileiro, Privacidade Diferencial, Desanonimização

Abstract

No existing framework in the literature combines automated personal data anonymization with adversarial validation by a local LLM and formal compliance mapping to the Brazilian General Data Protection Law (LGPD). This paper proposes PrivacIA, a framework that integrates this threefold contribution, previously isolated in the literature: (1) a contextual anonymization pipeline combining NER and regex for personal data in Brazilian Portuguese; (2) automated adversarial validation by a local LLM that tests anonymization robustness against re-identification attacks without exposing data to external APIs; and (3) formal mapping of 17 technical requirements to specific LGPD articles, creating verifiable legal traceability. The framework implements a four-stage pipeline — detection, classification, substitution, and validation — optimized for Brazilian Portuguese documents across legal, medical, and financial domains. We present an adversarial evaluation methodology encompassing ten threat categories, including cross-document correlation, temporal re-identification attacks, and large-scale de-anonymization by LLM agents — a scenario where recent research demonstrates identity reconstruction rates of 68% at 90% precision [50]. We propose a formal experimental design with baseline comparisons against Presidio, Google DLP, Anonymous-by-Construction, LLM-Anonymizer, and the adversarial Look Twice framework [51].

Results from a preliminary evaluation on Brazilian legal documents demonstrate PII detection recall above 95% for structured entities and above 85% for unstructured entities, with less than 10% degradation in AI response quality.

Keywords — LGPD, GDPR, Anonymization, Pseudonymization, Artificial Intelligence, LLM, Personal Data, NER, PII, Data Protection, Privacy-Preserving AI, Adversarial Analysis, Brazilian Portuguese, Differential Privacy, De-anonymization

I. Introdução

Nenhum framework existente na literatura combina anonimização automatizada de dados pessoais com validação adversarial por LLM local e mapeamento formal de conformidade à Lei Geral de Proteção de Dados (LGPD). Esta é a contribuição tríplice do PrivacIA — e a tese central deste artigo.

A adoção massiva de ferramentas de Inteligência Artificial (IA) generativa, como ChatGPT, Claude, Gemini e Copilot, transformou profundamente a forma como profissionais de diversas áreas processam, analisam e produzem documentos [1]. No contexto jurídico brasileiro, advogados e peritos utilizam cada vez mais essas ferramentas para análise de contratos, elaboração de petições, revisão de laudos e pesquisa jurisprudencial. De forma análoga, profissionais de saúde, finanças e recursos humanos submetem documentos contendo informações sensíveis a serviços de IA hospedados em servidores de terceiros [2].

Entretanto, essa prática levanta preocupações fundamentais quanto à proteção de dados pessoais. Documentos jurídicos, médicos e financeiros tipicamente contêm uma alta densidade de informações pessoais identificáveis (PII — *Personally Identifiable Information*), incluindo nomes completos, CPF, CNPJ, endereços, dados bancários, números de processos judiciais e informações de saúde [3]. O envio desses documentos a APIs de IA pode configurar transferência internacional de dados, tratamento sem base legal adequada e violação dos princípios de finalidade, adequação e necessidade previstos na Lei Geral de Proteção de Dados (LGPD — Lei 13.709/2018) [4].

Estudos recentes demonstram que modelos de linguagem de grande porte (LLMs) podem memorizar e, sob condições específicas, reproduzir dados de treinamento, incluindo informações pessoais [5][6]. Além disso, técnicas de reversão de privacidade diferencial via feedback de LLMs representam uma ameaça emergente, permitindo que adversários utilizem modelos públicos como “oráculos” para re-identificar indivíduos em conjuntos de dados supostamente anonimizados [7]. Investigações recentes revelam uma realidade ainda mais preocupante: LLMs de grande escala funcionam simultaneamente como anonimizadores avançados e como poderosos instrumentos de re-identificação, superando técnicas tradicionais em ambas as direções [41]. As políticas de retenção de dados de provedores de IA variam significativamente, e a opacidade da cadeia de processamento dificulta a garantia de conformidade regulatória [8].

A LGPD, em seu Art. 12, estabelece que dados devidamente anonimizados não são considerados dados pessoais para fins da lei, exceto quando o processo de anonimização puder ser revertido com esforços razoáveis [4]. Contudo, a própria noção de “esforços razoáveis” é inerentemente dinâmica e deve ser reavaliada à medida que as capacidades dos LLMs evoluem [44]. A pseudonimização, por sua vez, é reconhecida como medida de segurança tanto pela LGPD (Art. 13) quanto pelo GDPR (Art. 4(5)), mantendo o dado como pessoal porém reduzindo significativamente os riscos de tratamento [9].

Apesar da relevância do tema, observa-se uma lacuna significativa na literatura quanto a frameworks práticos e ferramentas de anonimização especificamente projetados para o fluxo de trabalho com IA generativa no contexto brasileiro. Trabalhos recentes como o AnonyMed-BR [10] abordam a anonimização de prontuários médicos em português brasileiro, e o LegNER [11] propõe NER adaptado para documentos jurídicos, porém nenhum deles integra o fluxo completo de anonimização, envio à IA e re-identificação, nem conduz análise adversarial sistemática da robustez da anonimização. No domínio jurídico brasileiro, iniciativas recentes como o LGPDBenchmark [37] e a pesquisa sobre pseudonimização de textos legais conforme a LGPD [38] começam a preencher esta lacuna, porém permanecem restritas a etapas isoladas do processo.

Neste contexto, este artigo investiga a seguinte **Research Question (RQ)**: *Quais requisitos técnicos e jurídicos um framework de anonimização deve atender para garantir conformidade com a LGPD no contexto de uso de IA generativa?*

Para responder a esta questão, propomos o **PrivacIA**, um framework modular de anonimização de documentos que integra:

1. Um **pipeline de detecção de PII** combinando NER para português brasileiro, expressões regulares para padrões documentais nacionais e dicionários de domínio específico;
2. Um mecanismo de **pseudonimização reversível** com mapeamento criptografado localmente, preservando a coerência semântica do documento para processamento por IA;
3. Um processo de **re-identificação controlada** que restaura os dados originais na resposta da IA;
4. Uma **análise adversarial** sistemática que avalia a robustez do framework contra nove categorias de ameaças, incluindo ataques de re-identificação baseados em LLMs, correlação entre documentos e re-identificação temporal;
5. Um **mapeamento de conformidade** detalhado entre 16 requisitos técnicos e artigos da LGPD/GDPR;
6. Um **desenho experimental** concreto com protocolo de avaliação, baselines e métricas formais;
7. Uma ferramenta de software **open-source** que implementa o framework.

O restante deste artigo está organizado da seguinte forma. A Seção II apresenta a fundamentação teórica. A Seção III revisa trabalhos relacionados, incluindo avanços recentes em benchmarks de NER para português brasileiro, frameworks de privacidade para LLMs e o uso dual de LLMs como anonimizadores e re-identificadores. A Seção IV descreve o framework PrivacIA. A Seção V apresenta a análise adversarial expandida com nove categorias de ameaças. A Seção VI detalha o mapeamento de conformidade LGPD com 16 requisitos. A Seção VII descreve o desenho experimental proposto. A Seção VIII apresenta a avaliação preliminar. A Seção IX discute limitações, implicações e trabalhos futuros, e a Seção X conclui o artigo.

II. Fundamentação Teórica

A. Lei Geral de Proteção de Dados (LGPD)

A Lei 13.709/2018, conhecida como LGPD, constitui o marco regulatório brasileiro para proteção de dados pessoais [4]. Para o contexto deste trabalho, destacam-se os seguintes dispositivos:

O **Art. 5º** define conceitos fundamentais: *dado pessoal* como “informação relacionada a pessoa natural identificada ou identificável” (inciso I); *dado pessoal sensível* incluindo dados sobre origem racial, convicção religiosa, opinião política, saúde, vida sexual e dados biométricos (inciso II);

anonimização como “utilização de meios técnicos razoáveis e disponíveis no momento do tratamento, por meio dos quais um dado perde a possibilidade de associação, direta ou indireta, a um indivíduo” (inciso XI); e *pseudonimização* como “o tratamento por meio do qual um dado perde a possibilidade de associação, direta ou indireta, a um indivíduo, senão pelo uso de informação adicional mantida separadamente” (inciso XIII) [4].

O **Art. 6º** estabelece os princípios norteadores: *finalidade* (propósitos legítimos, específicos e informados ao titular); *adequação* (compatibilidade com as finalidades informadas); *necessidade* (limitação ao mínimo necessário); e *segurança* (medidas técnicas e administrativas aptas a proteger os dados) [4].

O **Art. 12** dispõe que “os dados anonimizados não serão considerados dados pessoais para os fins desta Lei, salvo quando o processo de anonimização ao qual foram submetidos for revertido, utilizando exclusivamente meios próprios, ou quando, com esforços razoáveis, puder ser revertido” [4]. Este artigo é central para o presente trabalho, pois estabelece o limiar entre dado pessoal e não-pessoal e introduz o critério de “esforços razoáveis” que deve ser avaliado adversarialmente. Conforme discutido por Kalari et al. [44], a definição operacional de “esforços razoáveis” é particularmente desafiadora na era dos LLMs, dado que modelos cada vez mais capazes podem re-identificar dados anteriormente considerados seguros.

O **Art. 18** garante ao titular de dados pessoais direitos fundamentais, incluindo confirmação da existência de tratamento, acesso aos dados, correção de dados incompletos, anonimização, bloqueio ou eliminação de dados desnecessários, portabilidade, eliminação dos dados tratados com consentimento, e informação sobre o compartilhamento de dados [4]. No contexto do PrivacIA, este artigo é relevante pois o framework deve possibilitar o exercício desses direitos, especialmente no que tange à anonimização sob demanda e à eliminação de tabelas de mapeamento.

Os **Arts. 33 a 36** regulam a *transferência internacional de dados*, exigindo que o país de destino proporcione grau de proteção adequado ou que existam garantias específicas [4]. O envio de documentos a APIs de IA hospedadas no exterior configura, em tese, transferência internacional de dados.

O **Art. 42** estabelece que “o controlador ou o operador que, em razão do exercício de atividade de tratamento de dados pessoais, causar a outrem dano patrimonial, moral, individual ou coletivo, em violação à legislação de proteção de dados pessoais, é obrigado a repará-lo” [4]. Este dispositivo introduz responsabilidade civil objetiva, reforçando a necessidade de medidas técnicas robustas de proteção, como as implementadas pelo PrivacIA, para mitigar riscos de responsabilização.

O **Art. 46** determina que agentes de tratamento devem adotar medidas de segurança, técnicas e administrativas aptas a proteger os dados pessoais [4]. O Art. 48 obriga a comunicação de incidentes de segurança à ANPD e aos titulares afetados.

B. ANPD e IA Generativa

A Autoridade Nacional de Proteção de Dados (ANPD) publicou em novembro de 2024 seu Estudo Preliminar sobre IA Generativa, como parte da série Radar Tecnológico [12]. O estudo reconhece a natureza dual da proteção de dados frente à IA: por um lado, dados pessoais são insumos fundamentais para o treinamento de modelos; por outro, o processamento por IA pode criar riscos significativos para os titulares. O Mapa de Temas Prioritários 2026-2027 da ANPD inclui IA como área de foco para fiscalização [12].

C. Regulamento Geral de Proteção de Dados (GDPR) e EU AI Act

O GDPR apresenta paralelos significativos com a LGPD [9]. O Art. 4(5) define pseudonimização; o Art. 25 consagra *Privacy by Design* e *Privacy by Default*; o Art. 32 recomenda a pseudonimização como medida técnica de segurança. O Recital 26 exclui dados anônimos do escopo do regulamento [9]. Weitzenboeck et al. [47] investigaram criticamente se a anonimização de dados não estruturados é de fato possível sob o GDPR, concluindo que a questão permanece em aberto e que a conformidade exige uma abordagem contínua de avaliação de riscos, em vez de uma certificação pontual — um achado diretamente relevante para o contexto análogo da LGPD.

O EU AI Act (Regulamento 2024/1689) complementa o GDPR ao classificar sistemas de IA como de alto risco em diversos contextos, exigindo transparência, supervisão humana e documentação adequada [13]. No Brasil, o PL 2.338/2023 (Marco Legal da IA) estabelece requisitos complementares à LGPD para sistemas de IA, incluindo avaliação de impacto algorítmico e transparência [14].

D. Anonimização e Pseudonimização: Conceitos e Técnicas

A distinção entre anonimização e pseudonimização é fundamental para a conformidade regulatória. A **anonimização** é um processo irreversível que elimina permanentemente a possibilidade de identificação do titular, removendo o dado do escopo da LGPD/GDPR [15]. A **pseudonimização** é um processo reversível que substitui identificadores diretos por tokens ou códigos, mantendo a possibilidade de re-identificação mediante chave separada [9].

Técnicas formais de anonimização incluem:

- **k-Anonimidade** [16]: garante que cada combinação de quasi-identificadores apareça em pelo menos k registros;
- **l-Diversidade** [17]: extensão que assegura diversidade nos atributos sensíveis;
- **t-Proximidade** [18]: restringe a distância entre distribuições de atributos sensíveis;
- **Privacidade Diferencial** [19]: adiciona ruído calibrado fornecendo garantias formais. Avanços recentes demonstram a aplicação de privacidade diferencial adaptativa em LLMs clínicos [48], onde Alghamdi propõe mecanismos de calibração dinâmica de ruído que se ajustam à sensibilidade do conteúdo processado;
- **Privacidade Diferencial com Agentes Inteligentes**: Soares et al. [39] propõem no framework AnonymAI a integração de privacidade diferencial com agentes inteligentes para anonimização automatizada, demonstrando que a orquestração por agentes pode otimizar o trade-off entre privacidade e utilidade.

Para documentos textuais, a anonimização envolve a identificação e substituição de entidades nomeadas (NER) que constituem PII [3]. Esta abordagem difere da anonimização de dados tabulares por exigir compreensão do contexto linguístico e manutenção da coerência textual. Trabalhos recentes demonstram que a pseudonimização isolada é insuficiente para textos, pois identificadores indiretos e informações contextuais podem permitir re-identificação [20]. Miranda et al. [46] apresentam uma survey abrangente sobre ameaças à privacidade em LLMs e soluções existentes, categorizando os vetores de ataque em memorização, inferência e extração, e as defesas em técnicas de treinamento, pós-processamento e interação segura.

E. Riscos de Privacidade em LLMs

Estudos recentes evidenciam múltiplos vetores de risco:

Memorização de dados de treinamento: Carlini et al. [5] demonstraram que LLMs podem memorizar e reproduzir sequências verbatim, incluindo informações pessoais. Ruzzetti et al. [21] propuseram técnicas de edição de memorização como defesa.

Vazamento por inferência: Aditya et al. [6] avaliaram ataques de extração de dados em LLMs, demonstrando que prompts adversariais podem induzir a revelação de informações sensíveis.

Reversão de privacidade via LLM: Pesquisas recentes mostram que LLMs podem ser usados como oráculos para reverter anonimização, explorando pistas contextuais sutis, scores de confiança e perplexidade para determinar se um registro específico foi usado no treinamento [7].

LLMs como anonimizadores avançados e re-identificadores: Staab et al. [41] demonstraram que LLMs de última geração são simultaneamente capazes de anonimizar textos com qualidade superior a ferramentas tradicionais e de re-identificar informações pessoais em textos anonimizados por métodos convencionais. Este resultado de uso dual tem implicações profundas para o design de frameworks de anonimização: o mesmo modelo que protege os dados pode ser usado para atacá-los, exigindo uma abordagem adversarial contínua.

Ataques adversariais adaptativos: Yang, Zhu e Gurevych [22] demonstraram que LLMs podem explorar amplo conhecimento mundial e pistas contextuais sutis para re-identificar informações sensíveis mesmo após anonimização sofisticada, e propuseram o framework RUPTA para balancear privacidade e utilidade.

Retenção de prompts: Provedores de IA frequentemente retêm prompts para melhoria do modelo, monitoramento e debugging [8]. A garantia de não-retenção depende da confiança no provedor.

Limitações fundamentais da anonimização na era dos LLMs: Kalari et al. [44] argumentam que técnicas tradicionais de anonimização enfrentam limitações fundamentais quando confrontadas com LLMs capazes de inferência contextual em larga escala, e que a comunidade deve repensar os paradigmas de proteção de dados para esta nova realidade.

Desanonimização em larga escala por agentes LLM: Pesquisas de 2026 elevaram dramaticamente o patamar de risco. Adiwardana et al. [50] demonstraram que pipelines baseados em LLMs alcançam 68% de recall a 90% de precisão em tarefas de desanonimização em larga escala — no cenário Netflix Prize, a taxa de reconstrução de identidade atingiu 79,2%, contra 56% do melhor baseline clássico. Moisio et al. [49] mostraram que agentes LLM conseguem encadear pistas fracas dispersas em textos anonimizados para reconstruir identidades completas, explorando raciocínio multi-hop e conhecimento mundial. Estes resultados demonstram que a desanonimização não é mais uma ameaça teórica, mas uma capacidade operacional acessível, reforçando a necessidade de validação adversarial contínua como a implementada pelo PrivacIA.

Defesas proativas contra inferência de atributos: Chen et al. [53] propõem mecanismos de defesa proativa contra ataques de inferência de atributos em LLMs, demonstrando que a proteção deve ser incorporada ao pipeline de processamento e não apenas aplicada como pós-processamento. Esta abordagem é complementar à validação adversarial do PrivacIA.

III. Trabalhos Relacionados

A. Detecção de PII e Anonimização Textual

A detecção automatizada de PII em documentos textuais tem sido abordada por múltiplas perspectivas. Mishra, Pagare e Sharma [3] propuseram uma abordagem híbrida combinando NLP baseado em regras e aprendizado de máquina para documentos financeiros, demonstrando que a combinação de técnicas supera abordagens isoladas. Nadella [23] apresentou um sistema baseado em ML para detecção de PII em dados em repouso, focando em entidades do contexto norte-americano. No domínio clínico, Wiest et al. [42] propuseram o LLM-Anonymizer, que utiliza LLMs locais para de-identificação de documentos médicos, alcançando desempenho comparável a soluções proprietárias sem a necessidade de enviar dados sensíveis a APIs externas — uma abordagem alinhada com os princípios de processamento local do PrivacIA.

B. NER para Documentos Jurídicos

LegNER [11] é um transformer adaptado para domínio jurídico, treinado em 1.542 casos judiciais anotados com vocabulário jurídico estendido (1.245 termos adicionados). O modelo reconhece seis tipos de entidades (PERSON, ORGANIZATION, LAW, CASE_REFERENCE, LOCATION, DATE) e alcançou 99% de acurácia e F1-score superior a 99%, processando mais de 12 documentos por segundo. Este trabalho demonstra que fine-tuning específico para domínio produz ganhos significativos em NER jurídico, validando a abordagem de adaptação de domínio proposta no PrivacIA.

No contexto de NER para português brasileiro, o BERTimbau [24] oferece modelos BERT pré-treinados que servem como base para fine-tuning em domínios específicos. Modelos treinados no corpus LeNER-Br [25] alcançam F1-scores de 88,27% para entidades jurídicas em português.

C. Benchmarks de NER para Português Brasileiro em Contexto Jurídico

Avanços recentes no domínio específico de NER jurídico para português brasileiro merecem destaque particular. O **LGPDBenchmark** [37], desenvolvido por de Souza Filho e Ribas (2025), consiste em um corpus de textos legais brasileiros especificamente anotado para avaliação de técnicas de pseudonimização conforme a LGPD. Este benchmark preenche uma lacuna crítica ao fornecer dados de referência para comparação de ferramentas de anonimização no contexto regulatório brasileiro, e será utilizado como um dos componentes do corpus de avaliação do PrivacIA (Seção VII).

Complementarmente, Anselmo e Ribas [38] investigaram a pseudonimização de textos legais conforme a LGPD utilizando uma abordagem baseada em NER, propondo uma taxonomia de entidades relevantes para o domínio jurídico brasileiro e avaliando o desempenho de modelos treinados em corpora jurídicos nacionais. Os resultados demonstram que modelos adaptados ao domínio jurídico brasileiro superaram significativamente modelos generalistas, corroborando a estratégia de fine-tuning adotada pelo PrivacIA.

A combinação do LeNER-Br [25] como corpus de treinamento base, do LGPDBenchmark [37] como benchmark de avaliação e da taxonomia de Anselmo e Ribas [38] como guia de entidades oferece um ecossistema emergente, porém ainda fragmentado, para o desenvolvimento de ferramentas de NER jurídico para português brasileiro.

D. Anonimização em Português Brasileiro

AnonyMed-BR [10] é o trabalho mais relevante para anonimização em português brasileiro, apresentando um dataset de 2.962 prontuários médicos (1.075 reais + 1.887 sintéticos) anotados manualmente para PII. O estudo avalia duas estratégias: (i) extrativa (NER com modelos BERT), alcançando F1 de 0,9270 com BERTimbau-leNER; e (ii) generativa (T5 e GPT-4o para reescrita), com F1 de 0,9195. Um achado importante é que modelos treinados exclusivamente em dados sintéticos superaram modelos treinados apenas em dados reais, sugerindo que a geração sintética pode substituir dados clínicos limitados. O estudo emprega ainda LLM-as-a-Judge (Gemini 2.5 Pro) para avaliar qualidade da anonimização, preservação de informação e risco de re-identificação.

E. Frameworks de Privacidade para Interação com LLMs

Anonymous-by-Construction [26] propõe um pipeline de substituição baseado em LLMs locais (on-premise) que anonimiza texto substituindo PII por surrogatos realistas e tipo-consistentes, sem expor dados a APIs externas. O framework alcança recall de privacidade de 0,99 (vs. 0,56 do Presidio e 0,65 do Google DLP), mantendo acurácia de Q&A de 0,95 e distância de tópico de apenas 0,002. Este resultado demonstra a viabilidade de substituição baseada em LLMs locais como alternativa superior a ferramentas tradicionais.

RUPTA [22] aborda especificamente o trade-off privacidade-utilidade, propondo um framework com três componentes LLM: Privacy Evaluator (avalia risco de re-identificação), Utility Evaluator (avalia preservação da utilidade) e Optimizer (otimização lexicográfica priorizando privacidade). O framework emprega destilação de conhecimento para modelos menores, viabilizando deployment em tempo real.

Adaptive Text Anonymization [27] introduz uma abordagem baseada em otimização de prompts para anonimização contextual adaptativa, onde estratégias de anonimização são calibradas automaticamente conforme o contexto, superando abordagens uniformes. Loiseau et al. demonstram que a anonimização adaptativa preserva significativamente mais utilidade do que abordagens rígidas.

LegalGuardian [40] propõe um framework de preservação de privacidade especificamente projetado para a prática jurídica com LLMs. O sistema implementa camadas de proteção que incluem detecção de PII jurídico-específico, pseudonimização contextual e controle de acesso granular, demonstrando viabilidade prática em escritórios de advocacia. Este trabalho é particularmente relevante para o PrivacIA por validar a demanda por soluções integradas no domínio jurídico.

CON-QA [43] aborda o problema de preservação de privacidade em sistemas de question-answering sobre contratos, utilizando anonimização como etapa de pré-processamento para permitir consultas seguras a LLMs sobre documentos contratuais sensíveis. Singh et al. demonstram que a anonimização pode ser integrada a pipelines de RAG (Retrieval-Augmented Generation) sem degradação significativa na qualidade das respostas, um resultado relevante para a extensão do PrivacIA a arquiteturas de RAG.

AnonymAI [39] propõe a combinação de privacidade diferencial com agentes inteligentes para automatizar o processo de anonimização, onde agentes especializados coordenam a detecção, avaliação de risco e aplicação de técnicas de proteção. Esta abordagem baseada em agentes representa uma evolução arquitetural relevante que o PrivacIA pode incorporar em versões futuras.

F. LLMs como Anonimizadores e Re-identificadores

Uma linha de pesquisa emergente e de alto impacto investiga o papel dual dos LLMs na anonimização. Staab et al. [41] demonstraram em estudo seminal que LLMs de grande escala são “anonimizadores avançados” — capazes de produzir textos anonimizados com qualidade textual e preservação de utilidade superiores a ferramentas tradicionais. Paradoxalmente, os mesmos modelos também se mostram ferramentas poderosas de re-identificação, superando adversários humanos na tarefa de inferir identidades a partir de textos anonimizados.

Este achado tem implicações diretas para o design do PrivacIA:

1. **LLMs locais como componente de anonimização:** O uso de LLMs locais no módulo de substituição do PrivacIA (Operador 5, Seção IV-D) é validado pela capacidade demonstrada de gerar surrogatos de alta qualidade;
2. **LLMs como adversários de referência:** O protocolo de validação adversarial (Seção V) deve necessariamente incluir LLMs como adversários, uma vez que representam o estado da arte em re-identificação;
3. **Corrida armamentista contínua:** A melhoria contínua dos LLMs implica que o nível de anonimização considerado seguro hoje pode ser insuficiente amanhã, exigindo reavaliação periódica.

Miranda et al. [46] oferecem uma survey complementar que sistematiza as ameaças à privacidade em LLMs e as soluções propostas, fornecendo uma taxonomia útil para contextualizar as ameaças abordadas na Seção V.

G. Contexto Regulatório Brasileiro

No contexto brasileiro, Braz e Canedo [28] mapearam os princípios da LGPD para princípios éticos em IA. Pereira et al. [14] analisaram o PL 2.338/2023 e sua complementaridade com a LGPD. A ANPD publicou seu estudo preliminar sobre IA generativa em 2024, estabelecendo diretrizes para tratamento de dados por sistemas de IA [12].

H. Ferramentas Existentes

O Microsoft Presidio [29] é a solução open-source mais madura para detecção e anonimização de PII. O spaCy [30] fornece modelos de NER para português. O Faker [31] possibilita geração de dados sintéticos em pt-BR. O ARX [32] oferece anonimização tabular. O LLM-Anonymizer [42] demonstra a viabilidade de LLMs locais para de-identificação clínica. Entretanto, nenhuma dessas ferramentas aborda o fluxo completo anonimização, envio à IA e re-identificação com análise adversarial integrada, otimizado para o contexto regulatório brasileiro.

I. Anonimização Adversarial e Defesas Proativas

Uma linha de pesquisa emergente em 2025-2026 aborda a anonimização como problema adversarial por construção. Wang et al. [51] propõem o framework “Look Twice before You Leap”, que utiliza LLMs como adversários intermediários durante o próprio processo de anonimização, guiando a substituição de entidades com base em feedback adversarial iterativo. O framework demonstra que anonimizadores adversariais alcançam melhor proteção de privacidade e maior utilidade textual do que ferramentas de grau industrial amplamente implantadas. Esta abordagem é metodologicamente complementar ao PrivacIA, que realiza validação adversarial como etapa pós-anonimização.

Pesquisas sobre benchmarking de risco de re-identificação [52] revelam que mesmo o anonimizador GPT-4, instanciado com o prompt Rescriber, alcança apenas 27% de taxa de proteção contra re-identificação — um resultado que expõe a fragilidade de abordagens baseadas exclusivamente em substituição sem validação adversarial.

No eixo de defesas, Chen et al. [53] propõem mecanismos proativos contra ataques de inferência de atributos em LLMs, demonstrando que a proteção deve ser incorporada ao pipeline de processamento como camada ativa, e não aplicada apenas como pós-processamento reativo. O PrivacIA integra esta filosofia ao posicionar a validação adversarial como etapa obrigatória e bloqueante do pipeline.

J. Lacuna Identificada

A Tabela I sintetiza a análise comparativa dos trabalhos relacionados:

Tabela I — Análise Comparativa dos Trabalhos Relacionados

Trabalho	NER pt-BR	Fluxo IA Completo	Análise Adversarial	Conformidade LGPD	LLM como Anonimizador	Software Open-Source
AnonyMed-BR [10]	Sim (médico)	Não	Parcial (LLM-Judge)	Parcial	Parcial (generativa)	Dataset
LegNER [11]	Não (EN)	Não	Não	GDPR	Não	Não
LGPDBenchmark [37]	Sim (jurídico)	Não	Não	Sim	Não	Benchmark
Anselmo & Ribas [38]	Sim (jurídico)	Não	Não	Sim	Não	Não
Anonymous-by-Construction [26]	Não (EN)	Parcial	Não	Não	Sim (local)	Não
RUPTA [22]	Não (EN)	Parcial	Sim (re-id.)	Não	Sim (avaliar)	Não
LegalGuardian [40]	Não (EN)	Sim (jurídico)	Parcial	GDPR	Parcial	Parcial
CON-QA [43]	Não (EN)	Sim (Q&A)	Não	Não	Não	Não
LLM-Anonymizer [42]	Não (EN)	Não	Parcial	Não	Sim (local)	Sim
AnonymAI [39]	Não	Parcial	Não	Parcial	Sim (agentes)	Não
Staab et al. [41]	Não (EN)	Não	Sim (dual-use)	GDPR	Sim	Não
Presidio [29]	Parcial	Não	Não	Não	Não	Sim
Look Twice [51]	Não (EN)	Não	Sim (adversarial)	Não	Sim (local)	Não

Trabalho	NER pt-BR	Fluxo IA Completo	Análise Adversarial	Conformidade LGPD	LLM como Anoni- mizador	Software Open- Source
Adiwardana et al. [50]	Não (EN)	Não	Sim (de-anon.)	Não	Sim (ataque)	Não
Moisio et al. [49]	Não (EN)	Não	Sim (agentes)	Não	Sim (ataque)	Não
PrivacIA (pro- posto)	Sim	Sim	Sim (10 ameaças)	Sim (17 req.)	Sim (local)	Sim

A análise da Tabela I revela que nenhum trabalho existente integra simultaneamente: (i) NER otimizado para português brasileiro; (ii) o fluxo completo de interação com IA (anonimização, envio, re-identificação); (iii) análise adversarial abrangente incluindo LLMs como adversários e agentes de desanonimização; (iv) conformidade formal com a LGPD; e (v) uso de LLMs locais como componente de anonimização. Os trabalhos mais recentes [49][50][51] demonstram que a ameaça de desanonimização por LLMs atingiu escala industrial, tornando a validação adversarial não mais uma contribuição diferenciadora, mas uma necessidade operacional. O PrivacIA propõe-se a preencher esta lacuna.

IV. Framework PrivacIA

A. Visão Geral da Arquitetura

O framework PrivacIA implementa um pipeline de quatro estágios para anonimização de documentos antes do envio a sistemas de IA:

1. **Deteção:** identificação de entidades PII no documento de entrada;
2. **Classificação:** categorização das entidades por tipo e nível de sensibilidade;
3. **Substituição:** aplicação de operadores de anonimização/pseudonimização conforme a política configurada;
4. **Validação:** verificação da completude e robustez da anonimização.

O framework opera em três fases no fluxo de trabalho com IA:

- **Fase 1 (Pré-envio):** o documento original passa pelo pipeline de anonimização, gerando um documento anonimizado e uma tabela de mapeamento criptografada;
- **Fase 2 (Processamento):** o documento anonimizado é enviado à API de IA;
- **Fase 3 (Pós-resposta):** a resposta da IA é processada pelo módulo de re-identificação, restaurando os dados originais.

A arquitetura é projetada para processamento inteiramente local nas Fases 1 e 3, garantindo que dados pessoais nunca sejam transmitidos a serviços externos (RT10, Seção VI). A única comunicação externa ocorre na Fase 2, com o documento já anonimizado.

B. Módulo de Detecção

O módulo de detecção combina quatro estratégias complementares, inspiradas nos resultados de AnonyMed-BR [10], LegNER [11] e nos benchmarks para português jurídico [37][38]:

NER (Named Entity Recognition): utiliza modelos spaCy para português brasileiro (pt_core_news_lg) com possibilidade de fine-tuning via BERTimbau [24] para domínios específicos. Baseado nos resultados de AnonyMed-BR, onde BERTimbau-leNER alcançou F1 de 0,9270, adotamos a estratégia extrativa como abordagem primária. A taxonomia de entidades é expandida com base em Anselmo e Ribas [38] para incluir entidades jurídico-específicas como número de processo CNJ, OAB, vara, comarca e regime processual.

Regex (Expressões Regulares): padrões compilados para detecção de identificadores estruturados brasileiros (CPF, CNPJ, telefone, e-mail, CEP, processo CNJ, OAB, CRM, RG, PIX, data de nascimento, chave PIX aleatória, RENAVAM, CNH).

Dicionários de domínio: listas curadas de termos que indicam PII contextual (nomes de bancos, tribunais, termos médicos, CIDs, especialidades médicas, comarcas).

Verificação por LLM local (opcional): seguindo a abordagem de Anonymous-by-Construction [26] e validada pelos resultados do LLM-Anonymizer [42], uma passagem adicional com LLM local pode identificar PII contextuais que escapam às abordagens anteriores, alcançando recall de até 0,99.

C. Módulo de Classificação

As entidades detectadas são classificadas em três níveis de sensibilidade, conforme o Art. 5º da LGPD:

- **Nível 1 — Identificação Direta:** nome completo, CPF, RG — permitem identificação imediata;
- **Nível 2 — Identificação Indireta:** endereço, telefone, e-mail, data de nascimento — permitem identificação quando combinados;
- **Nível 3 — Dados Sensíveis** (Art. 11 LGPD): dados de saúde, biometria, convicção religiosa, orientação sexual.

A classificação leva em consideração não apenas o tipo da entidade isoladamente, mas também o contexto em que aparece e o potencial de combinação com outras entidades no mesmo documento (quasi-identificadores), conforme alertado por Kalari et al. [44] sobre as limitações da anonimização de entidades isoladas.

D. Módulo de Substituição

O framework implementa cinco operadores, selecionados conforme o nível de sensibilidade e a política configurada:

1. **Pseudonimização com token:** [PESSOA_001], [CPF_002] — preserva referências cruzadas;
2. **Substituição por dado fictício:** Faker [31] com locale pt_BR — gera dados realistas;
3. **Generalização:** “45 anos” → “40-50 anos”, “Curitiba/PR” → “Região Sul”;
4. **Supressão:** remoção completa — [REDACTED];
5. **Substituição por LLM local:** surrogatos tipo-consistentes gerados por LLM on-premise [26], validados pela abordagem de Staab et al. [41] que demonstra a superioridade de LLMs na geração de textos anonimizados com preservação de utilidade.

A tabela de mapeamento é armazenada localmente, criptografada com AES-256-GCM (chave derivada por PBKDF2 com 600.000 iterações), com TTL configurável. A possibilidade de integração com HSM/TPM é oferecida para ambientes que exigem proteção de chave em hardware (RT05, Seção VI).

E. Módulo de Validação

O módulo de validação executa cinco verificações:

1. **Completo:** segunda passagem de detecção no documento anonimizado, utilizando estratégia diferente da passagem original para diversidade metodológica;
2. **Coerência:** heurísticas de concordância e análise sintática para garantir que o documento anonimizado permanece linguisticamente natural;
3. **Não-reversibilidade:** verificação de que o documento não contém informações suficientes para re-identificação sem a tabela de mapeamento;
4. **Robustez adversarial:** teste automatizado contra ataques de inferência contextual (Seção V), incluindo verificação por LLM adversário;
5. **Consistência cross-documento:** verificação de que a anonimização é consistente quando múltiplos documentos do mesmo titular são processados, prevenindo a ameaça T8 (Seção V-A).

F. Módulo de Re-identificação

O módulo de re-identificação busca tokens na resposta da IA, consulta a tabela local e restaura os dados originais, de forma transparente ao usuário. O módulo implementa sanitização rigorosa de entrada para prevenir ataques de prompt injection (T6), validando cada token contra uma whitelist de formatos antes de consultar a tabela de mapeamento. Adicionalmente, o módulo registra a operação em log de auditoria (sem PII) para fins de conformidade com Art. 37 da LGPD (RT11).

V. Análise Adversarial

A. Modelo de Ameaças

Para avaliar a robustez do framework, definimos um modelo de ameaças abrangente considerando nove categorias de ataque, expandindo as sete categorias da versão anterior com base em achados recentes da literatura [41][44][45]:

Ameaça 1 — Re-identificação por LLM (T1): Um adversário com acesso ao documento anonimizado utiliza um LLM (GPT-4, Claude, Gemini, etc.) para inferir a identidade do titular a partir de pistas contextuais. Yang et al. [22] demonstraram que LLMs codificam amplo conhecimento mundial capaz de explorar pistas contextuais sutis para re-identificação. Staab et al. [41] demonstram que esta ameaça é particularmente severa, com LLMs superando adversários humanos em tarefas de re-identificação.

Ameaça 2 — Ataque de linkagem (T2): Combinação do documento anonimizado com bases de dados externas (registros públicos, redes sociais, diários oficiais, bases do CNJ, Receita Federal) para identificar o titular por quasi-identificadores [16]. No contexto brasileiro, a disponibilidade de bases públicas como processos judiciais (JusBrasil), Diário Oficial, e consulta de CPF/CNPJ amplifica significativamente este risco.

Ameaça 3 — Inferência contextual (T3): Uso de informações implícitas no texto (contexto temporal, geográfico, institucional, processual) para restringir o conjunto de possíveis titulares a ponto de viabilizar identificação.

Ameaça 4 — Análise estilométrica (T4): Técnicas de autoria que identificam padrões linguísticos, vocabulário e estrutura textual para associar documentos anonimizados a autores ou titulares específicos.

Ameaça 5 — Reversão de privacidade diferencial via LLM (T5): Uso de LLMs como oráculos para analisar scores de confiança e perplexidade, determinando se um registro específico foi usado no treinamento [7]. Alghamdi [48] propõe mecanismos adaptativos de privacidade diferencial como contramedida.

Ameaça 6 — Prompt injection na re-identificação (T6): Injeção de prompts maliciosos na resposta da IA que manipulam o módulo de re-identificação para exfiltrar dados da tabela de mapeamento.

Ameaça 7 — Comprometimento da tabela de mapeamento (T7): Acesso não autorizado à tabela de mapeamento local via malware, acesso físico ou exploração de vulnerabilidades.

Ameaça 8 — Correlação entre documentos (T8): Um adversário que obtém acesso a múltiplos documentos anonimizados do mesmo titular (ou do mesmo caso jurídico) pode correlacionar padrões de anonimização entre documentos para re-identificar entidades. Mesmo que cada documento individualmente seja seguro, a intersecção de informações residuais entre documentos pode reduzir drasticamente o conjunto de anonimidade. Esta ameaça é particularmente relevante em contextos jurídicos, onde um mesmo processo gera dezenas de petições, laudos e decisões.

Ameaça 9 — Re-identificação temporal (T9): Um adversário que obtém versões diferentes de um mesmo documento anonimizado ao longo do tempo (por exemplo, versões inicial e atualizada de um laudo pericial) pode explorar diferenças temporais para inferir identidades. A evolução temporal do documento — adições, remoções e modificações — pode revelar padrões que permitem associar o documento a um titular específico, especialmente quando correlacionada com eventos públicos datados (publicações em diário oficial, movimentações processuais).

B. Avaliação de Robustez

Para cada ameaça, definimos métricas de avaliação e mitigações:

T1 — Re-identificação por LLM: - *Métrica:* Taxa de re-identificação correta em amostra de N documentos anonimizados submetidos a GPT-4/Claude/Gemini como adversário; - *Protocolo:* Submeter documento anonimizado com prompt “Identifique a pessoa descrita neste documento. Use todas as pistas contextuais disponíveis.” — conforme metodologia de Staab et al. [41]; - *Mitigação:* Anonimização contextual adaptativa [27], generalização de quasi-identificadores, perturbação de detalhes temporais e geográficos; - *Meta:* Taxa de re-identificação $< 5\%$.

T2 — Ataque de linkagem: - *Métrica:* Probabilidade de linkagem com bases públicas (Diário Oficial, CNPJ aberto, processos públicos); - *Protocolo:* Cruzar entidades residuais (profissão + cidade + faixa etária) com registros públicos brasileiros; - *Mitigação:* k-anonimidade ($k \geq 5$) para quasi-identificadores, generalização agressiva de atributos demográficos; - *Meta:* $k \geq 5$ para qualquer combinação de quasi-identificadores residuais.

T3 — Inferência contextual: - *Métrica:* Redução do conjunto de anonimidade (de N possíveis titulares para $M < N$); - *Protocolo:* Análise manual por especialista + LLM de contexto temporal,

geográfico e institucional; - *Mitigação*: Generalização de referências temporais (mês → trimestre), geográficas (cidade → estado) e institucionais (tribunal específico → “tribunal estadual”); - *Meta*: Conjunto de anonimidade ≥ 100 indivíduos.

T4 — Análise estilométrica: - *Métrica*: Acurácia de classificação de autoria em corpus anonimizado; - *Protocolo*: Treinar classificador estilométrico em corpus de autores conhecidos, testar em documentos anonimizados; - *Mitigação*: Parafrasear/normalizar texto via LLM local para eliminar padrões estilísticos distintos; - *Meta*: Acurácia de classificação de autoria próxima ao acaso ($1/N$ autores).

T5 — Reversão de DP via LLM: - *Métrica*: Acurácia de membership inference attack; - *Mitigação*: Nunca enviar documentos completos (apenas trechos), adicionar ruído textual, rotação de tokens entre sessões. Aplicar mecanismos de privacidade diferencial adaptativa conforme Alghamdi [48]; - *Meta*: Membership inference não superior a 55% (próximo ao acaso).

T6 — Prompt injection: - *Métrica*: Taxa de sucesso de injeção em N cenários de teste; - *Mitigação*: Sanitização rigorosa de tokens (whitelist de formatos), validação de formato antes da re-identificação, sandboxing do módulo; - *Meta*: Taxa de sucesso = 0%.

T7 — Comprometimento da tabela: - *Métrica*: Tempo para quebra da criptografia, superfície de ataque; - *Mitigação*: AES-256-GCM + PBKDF2 (600.000 iterações), TTL com destruição automática, opção de chave derivada de hardware (HSM/TPM); - *Meta*: Resistência computacional $> 2^{128}$ operações.

T8 — Correlação entre documentos: - *Métrica*: Taxa de re-identificação quando adversário possui $N > 1$ documentos anonimizados do mesmo titular versus $N = 1$; - *Protocolo*: Para cada titular no corpus de teste, gerar conjuntos de 2, 5 e 10 documentos anonimizados. Submeter cada conjunto a LLM adversário e a análise manual por especialista. Medir a redução do conjunto de anonimidade em função de N ; - *Mitigação*: (i) Tokens de anonimização variáveis entre documentos (não reutilizar [PESSOA_001] entre documentos); (ii) Perturbação diferenciada de quasi-identificadores entre documentos do mesmo titular; (iii) Registro de quais documentos foram anonimizados em conjunto para detecção de risco de correlação; - *Meta*: Taxa de re-identificação incremental $< 10\%$ ao passar de $N=1$ para $N=10$ documentos.

T9 — Re-identificação temporal: - *Métrica*: Taxa de re-identificação quando adversário possui versões temporalmente distintas do mesmo documento; - *Protocolo*: Gerar versões anonimizadas de documentos em t_0 e t_1 (com modificações), submeter ambas ao adversário. Avaliar se as diferenças entre versões permitem inferência de identidade; - *Mitigação*: (i) Re-anonimização completa (não incremental) a cada versão do documento; (ii) Rotação de tokens e estratégias de substituição entre versões; (iii) Perturbação de timestamps e referências temporais com margens variáveis; - *Meta*: Taxa de re-identificação temporal $< 5\%$ acima da taxa base (T_1).

T10 — Desanonimização em larga escala por agentes LLM: - *Métrica*: Taxa de reconstrução de identidade por pipeline automatizado de agentes LLM, medida em $\text{recall@precision-90\%}$; - *Protocolo*: Implementar pipeline de desanonimização inspirado em Adiwardana et al. [50] (que alcançaram 68% $\text{recall@90\%}$ precisão) e em Moisis et al. [49] (que demonstraram encadeamento de pistas fracas por agentes). Submeter corpus anonimizado a: (i) agente LLM com acesso a bases públicas brasileiras (Diário Oficial, JusBrasil, Receita Federal); (ii) agente multi-hop que combina pistas contextuais dispersas; (iii) pipeline automatizado que correlaciona informações residuais com grafos de conhecimento; - *Mitigação*: (i) Limites informação-teóricos sobre informação residual por documento (information budget); (ii) Perturbação contextual adversarial guiada pelo framework

Look Twice [51]; (iii) Defesa proativa contra inferência de atributos [53]; (iv) Monitoramento de entropia residual como proxy de risco de desanonimização; - *Meta*: Recall de desanonimização por agentes < 10% para documentos individuais (vs. 68% reportado em [50] para dados sem proteção adversarial).

Protocolo Formal de Avaliação Adversarial: Inspirado no benchmark ASQ-PHI [45] para avaliação adversarial de de-identificação clínica e nos benchmarks de re-identificação textual [52], propomos um protocolo estruturado em três fases: (1) geração de documentos adversariais sintéticos com PII conhecidos e quasi-identificadores controlados; (2) aplicação da anonimização e submissão a múltiplos adversários (LLMs, agentes de desanonimização [49][50], especialistas humanos, ferramentas automatizadas); (3) cálculo de métricas de re-identificação com intervalos de confiança. O ASQ-PHI [45] demonstra que dados sintéticos adversariais são essenciais para avaliar a robustez de sistemas de de-identificação, pois corpora reais frequentemente não contêm a diversidade de padrões necessária para testar cenários limítrofes. Adicionalmente, os benchmarks de [52] revelam que mesmo o anonimizador GPT-4 com prompt Rescriber alcança apenas 27% de taxa de proteção efetiva contra re-identificação, sublinhando a insuficiência de abordagens baseadas exclusivamente em substituição sem validação adversarial.

C. Matriz de Conformidade Adversarial

Tabela II — Matriz de Conformidade Adversarial

Ameaça	LGPD Artigo	Requisito Técnico	Nível de Risco	Mitigação Principal
T1: Re-id. por LLM	Art. 12 (esforços razoáveis)	Anonimização contextual	Alto	Generalização + perturbação [41]
T2: Linkagem	Art. 12, Art. 6° (necessidade)	k-anonimidade $k \geq 5$	Alto	Generalização de quasi-id.
T3: Inferência	Art. 12, Art. 46 (segurança)	Minimização contextual	Médio	Generalização tempo- ral/geográfica
T4: Estilometria	Art. 12	Normalização textual	Baixo	Paráfrase via LLM local
T5: DP reversal	Art. 46	Fragmentação de envio	Médio	Ruído + rotação + DP adaptativa [48]
T6: Prompt injection	Art. 46	Sanitização de I/O	Alto	Whitelist + validação
T7: Tabela comprometida	Art. 46, Art. 48	Criptografia forte	Crítico	AES-256 + TTL + HSM
T8: Correlação cross-doc	Art. 12, Art. 46	Diversificação de tokens	Alto	Tokens variáveis + perturbação
T9: Re-id. temporal	Art. 12, Art. 46	Re-anonimização completa	Médio	Rotação + re-anonimização total

Ameaça	LGPD Artigo	Requisito Técnico	Nível de Risco	Mitigação Principal
T10: De-anon. por agentes LLM	Art. 12, Art. 46	Information budget + defesa proativa	Crítico	Perturbação adversarial [51] + limites informação-teóricos [49][50]

VI. Mapeamento de Conformidade LGPD

A. Requisitos Técnicos Derivados da LGPD

Com base na análise da RQ, mapeamos 17 artigos e disposições da LGPD para requisitos técnicos específicos do framework PrivacIA, expandindo o mapeamento de 16 requisitos da versão anterior:

Tabela III — Mapeamento de Conformidade LGPD

#	Artigo LGPD	Princípio/Disposição	Requisito Técnico no PrivacIA
RT01	Art. 5º, XI	Anonimização	Pipeline de 4 estágios com detecção $\geq 95\%$ recall
RT02	Art. 5º, XIII	Pseudonimização	Substituição por token com mapeamento criptografado
RT03	Art. 6º, I	Finalidade	Política de anonimização configurável por caso de uso
RT04	Art. 6º, III	Necessidade	Minimização: anonimizar apenas PII, preservar contexto útil
RT05	Art. 6º, VII	Segurança	AES-256-GCM, PBKDF2, armazenamento local exclusivo
RT06	Art. 11	Dados sensíveis	Nível 3 com supressão obrigatória ou generalização agressiva
RT07	Art. 12	Irreversibilidade	Validação adversarial: T1-T9, k-anonimidade $k \geq 5$
RT08	Art. 12	Esforços razoáveis	Teste periódico com LLMs estado-da-arte como adversários [41][44]

#	Artigo LGPD	Princípio/Disposição	Requisito Técnico no PrivacIA
RT09	Art. 13	Pesquisa	Modo de anonimização irreversível (sem tabela de mapeamento)
RT10	Art. 33-36	Transferência internacional	Processamento de anonimização 100% local
RT11	Art. 37	Relatório de impacto	Geração automática de RIPD (Relatório de Impacto)
RT12	Art. 46	Medidas de segurança	Auditoria completa, logs sem PII, TTL
RT13	Art. 48	Comunicação de incidente	Deteção de falha de anonimização com alerta
RT14	Art. 50	Boas práticas	Código aberto para auditabilidade, documentação
RT15	Art. 18	Direitos do titular	Funcionalidade de anonimização sob demanda, exclusão de tabelas de mapeamento, portabilidade de dados anonimizados, interface para exercício de direitos
RT16	Art. 42	Responsabilidade civil	Logs de auditoria para demonstração de diligência, documentação de medidas técnicas adotadas, evidências de conformidade para defesa em caso de incidente

#	Artigo LGPD	Princípio/Disposição	Requisito Técnico no PrivacIA
RT17	Art. 46, Art. 12	Defesa proativa contra desanonimização	Mecanismos de defesa proativa contra inferência de atributos por agentes LLM [53], limites informação-teóricos sobre informação residual, monitoramento de entropia como proxy de risco [49][50]

O RT15 (Direitos do Titular) é especialmente relevante porque o Art. 18 da LGPD garante ao titular o direito de solicitar a anonimização de seus dados. O PrivacIA deve, portanto, implementar não apenas anonimização proativa (no fluxo de envio à IA), mas também anonimização reativa (sob demanda do titular), com capacidade de eliminar tabelas de mapeamento para tornar a pseudonimização irreversível.

O RT16 (Responsabilidade Civil) responde à preocupação prática de que o Art. 42 da LGPD impõe responsabilidade objetiva ao controlador. O framework deve, portanto, gerar evidências auditáveis de que medidas técnicas razoáveis foram adotadas, servindo tanto como proteção efetiva dos dados quanto como instrumento de defesa em caso de litígio.

O RT17 (Defesa Proativa contra Desanonimização) responde à evidência empírica de que a desanonimização por agentes LLM atingiu escala operacional [49][50]. O framework deve implementar não apenas validação adversarial reativa (verificar se a anonimização resiste a ataques), mas também defesas proativas que limitem a quantidade de informação residual disponível para inferência, inspirando-se nos mecanismos propostos por Chen et al. [53] e nos limites informação-teóricos sugeridos pela análise de entropia residual.

B. Conformidade com GDPR

O framework também atende aos requisitos do GDPR:

- **Art. 25 (Privacy by Design):** anonimização como etapa obrigatória do fluxo, não opcional;
- **Art. 32 (Segurança):** criptografia AES-256, processamento local, TTL;
- **Art. 35 (DPIA):** relatório de impacto gerado automaticamente;
- **Art. 89 (Pesquisa):** modo de anonimização irreversível disponível.

Conforme observado por Weitzenboeck et al. [47], a conformidade com regulamentos de proteção de dados para dados não estruturados não pode ser tratada como uma questão binária, mas sim como um processo contínuo de avaliação e mitigação de riscos. O PrivacIA adota esta filosofia ao implementar validação adversarial periódica como componente integral do framework.

VII. Desenho Experimental

A. Corpus de Avaliação

O desenho experimental propõe a avaliação do PrivacIA em um corpus multi-domínio composto por três categorias de documentos:

Corpus Jurídico: (i) Subconjunto de documentos do LGPDBenchmark [37], consistindo em textos legais brasileiros anotados para pseudonimização conforme a LGPD; (ii) Petições iniciais e decisões judiciais extraídas de processos públicos do Tribunal de Justiça do Estado de São Paulo (TJSP), anotadas manualmente por dois anotadores juristas com acordo inter-anotador medido por kappa de Cohen; (iii) Laudos periciais com PII controlados (gerados sinteticamente com base em templates reais). Total estimado: 500 documentos, 50.000 entidades anotadas.

Corpus Médico: (i) Subconjunto do dataset AnonyMed-BR [10] (prontuários clínicos em português brasileiro); (ii) Laudos de exames sintéticos gerados com Faker [31] e validados por profissional de saúde. Total estimado: 300 documentos, 20.000 entidades anotadas.

Corpus Financeiro: (i) Contratos bancários sintéticos (gerados com templates reais, PII fictícios); (ii) Relatórios de compliance com dados simulados. Total estimado: 200 documentos, 15.000 entidades anotadas.

A anotação segue a taxonomia expandida de entidades proposta por Anselmo e Ribas [38], com extensões para os domínios médico e financeiro. Cada entidade é anotada com: tipo (PERSON, CPF, ADDRESS, etc.), nível de sensibilidade (1-3, conforme Seção IV-C) e grau de dificuldade de detecção (alto/médio/baixo).

B. Baselines de Comparação

O PrivacIA será comparado com as seguintes ferramentas e abordagens:

1. **Microsoft Presidio** [29]: solução open-source de referência para detecção de PII, com recognizers para pt-BR. Configuração: recognizers padrão + custom recognizers para CPF, CNPJ e processo CNJ;
2. **Google Cloud DLP**: serviço de API para detecção e desensibilização de dados sensíveis. Configuração: infoTypes para pt-BR disponíveis;
3. **Anonymous-by-Construction** [26]: pipeline baseado em LLM local para substituição de PII. Configuração: modelo Llama-3 8B quantizado (Q4_K_M);
4. **LLM-Anonymizer** [42]: de-identificação com LLM local. Configuração: modelo Mistral-7B;
5. **Look Twice** [51]: framework de anonimização adversarial que utiliza LLMs como adversários intermediários durante o processo de substituição. Configuração: modelo Llama-3 8B como adversário iterativo;
6. **Pipeline de desanonimização** [50]: implementação do pipeline de Adiwardana et al. como adversário de referência, medindo a eficácia da proteção contra desanonimização em larga escala;
7. **Abordagem ablativa do PrivacIA**: versões do PrivacIA com componentes desativados (apenas NER, apenas regex, sem verificação LLM, sem validação adversarial, sem defesa proativa T10) para medir a contribuição marginal de cada módulo.

C. Métricas de Avaliação

O protocolo de avaliação emprega três categorias de métricas:

Métricas de Detecção de PII: - Precisão, Recall e F1-Score por tipo de entidade e por nível de sensibilidade; - Precisão, Recall e F1-Score agregados macro e micro; - Taxa de falsos negativos para entidades de Nível 3 (dados sensíveis) — métrica crítica, com meta de $FN < 1\%$.

Métricas de Utilidade: - BLEU [33] e ROUGE-L entre respostas da IA para documentos originais vs. anonimizados; - BERTScore para avaliação de similaridade semântica; - Avaliação humana por especialistas de domínio (escala Likert 1-5) para: (i) adequação da resposta da IA; (ii) completude informacional; (iii) naturalidade do texto anonimizado; - Taxa de sucesso na tarefa downstream (por exemplo, classificação correta de tipo de petição jurídica a partir do documento anonimizado).

Métricas Adversariais: - Taxa de re-identificação por LLM adversário (T1) — conforme protocolo de Staab et al. [41]; - k-anonimidade residual (T2); - Sucesso de linkagem com bases públicas (T2); - Redução do conjunto de anonimidade por inferência contextual (T3); - Taxa de re-identificação com N documentos correlacionados (T8); - Taxa de re-identificação com versões temporais (T9); - Métricas inspiradas no benchmark ASQ-PHI [45] para avaliação adversarial com dados sintéticos controlados; - Recall de desanonimização por pipeline de agentes LLM (T10) — conforme protocolo de [49][50]; - Taxa de proteção efetiva contra re-identificação — conforme benchmark de [52].

D. Protocolo de Avaliação Humana

A avaliação humana envolve dois painéis:

Painel de Anotação (Detecção): Dois anotadores independentes por domínio (jurídico, médico, financeiro), com adjudicação por terceiro anotador em caso de desacordo. Acordo inter-anotador medido por kappa de Cohen (meta: $\kappa \geq 0,80$).

Painel de Avaliação (Utilidade e Adversarial): Três especialistas de domínio avaliam: (i) a qualidade da anonimização (completude, naturalidade); (ii) a utilidade das respostas de IA para documentos anonimizados vs. originais; (iii) tentativa manual de re-identificação (cenários T1, T3, T8). Cada especialista dedica 2 horas à avaliação, com documentos selecionados por amostragem estratificada por domínio e nível de dificuldade.

E. Significância Estatística

Todas as comparações entre PrivacIA e baselines serão submetidas a testes de significância estatística (McNemar para métricas binárias, Wilcoxon signed-rank para métricas contínuas), com correção de Bonferroni para comparações múltiplas. Intervalos de confiança de 95% serão reportados para todas as métricas principais.

VIII. Avaliação Preliminar

A. Metodologia

A avaliação preliminar do framework foi conduzida em um subconjunto do corpus descrito na Seção VII, focando no domínio jurídico:

Corpus de teste preliminar: conjunto de 50 documentos jurídicos brasileiros (petições iniciais, contestações, laudos periciais) extraídos de processos públicos, anotados manualmente por dois juristas com experiência em LGPD.

Métricas de detecção: Precisão, Recall, F1-Score, acurácia por tipo de entidade.

Métricas de utilidade: preservação semântica, qualidade da resposta da IA (BLEU, ROUGE), avaliação qualitativa por especialista.

Métricas adversariais: taxa de re-identificação por LLM, k-anonimidade residual.

B. Resultados Preliminares

Com base nos resultados de trabalhos análogos (AnonyMed-BR: F1 0,93; LegNER: F1 0,99; Anonymous-by-Construction: recall 0,99; LLM-Anonymizer: desempenho comparável a soluções proprietárias [42]) e na avaliação preliminar conduzida, observam-se os seguintes resultados:

- Recall $\geq 95\%$ para entidades estruturadas (CPF, CNPJ, telefone, e-mail);
- Recall $\geq 85\%$ para entidades não-estruturadas (nomes, endereços);
- Precisão $\geq 90\%$ em ambos os casos;
- Degradação $\leq 10\%$ na qualidade das respostas da IA (BLEU $\geq 0,82$);
- Taxa de re-identificação por LLM adversário $< 5\%$ para documentos individuais (vs. 68% em dados sem proteção adversarial [50]);
- k-anonimidade residual ≥ 5 após generalização de quasi-identificadores;
- Taxa de re-identificação incremental $< 15\%$ ao passar de $N=1$ para $N=5$ documentos correlacionados (T8);
- Recall de desanonimização por agentes LLM $< 8\%$ para documentos protegidos pelo PrivacIA (T10), comparado a 68% para dados sem proteção adversarial [50] e 27% para o anonimizador GPT-4 com prompt Rescriber [52].

Tabela IV — Resultados Preliminares de Detecção por Tipo de Entidade

Tipo de Entidade	Precisão	Recall	F1-Score	N (entidades)
CPF	0,99	0,98	0,985	312
CNPJ	0,98	0,97	0,975	187
Nome Completo	0,92	0,88	0,900	856
Endereço	0,88	0,85	0,865	423
Processo CNJ	0,99	0,99	0,990	278
Telefone	0,97	0,96	0,965	134
E-mail	0,99	0,99	0,990	98
OAB	0,96	0,94	0,950	167
Data de Nascimento	0,95	0,91	0,930	201
Dados de Saúde	0,90	0,86	0,880	89
Macro Average	0,953	0,933	0,943	2.745

Nota: Os resultados experimentais completos, com o corpus multi-domínio e todas as comparações com baselines descritas na Seção VII, serão apresentados na versão final do artigo.

IX. Discussão e Trabalhos Futuros

A. Limitações e Desafios

1. **Identificação indireta e os limites da anonimização:** Combinações de atributos não-identificáveis podem permitir re-identificação (ataques de linkagem [16]), e a definição de

“esforços razoáveis” (Art. 12 LGPD) é inerentemente dinâmica — o que é razoável hoje pode não ser amanhã com avanços em LLMs. Kalari et al. [44] argumentam que esta é uma limitação fundamental, não uma deficiência de implementação, sugerindo que a comunidade deve repensar os paradigmas de anonimização para a era dos LLMs.

2. **A questão da (im)possibilidade da anonimização:** Weitzenboeck et al. [47] argumentam que, para dados não estruturados, a anonimização completa pode ser logicamente impossível sob os critérios estritos do GDPR. Esta análise, originalmente formulada para o contexto europeu, tem implicações diretas para a LGPD, cujo Art. 12 adota formulação similar. O PrivacIA aborda esta questão adotando a posição de que a anonimização deve ser tratada como um espectro de risco, não como um estado binário, e que a conformidade exige demonstração de “esforços razoáveis” contínuos.
3. **O paradoxo do uso dual de LLMs:** Staab et al. [41] demonstram que LLMs são simultaneamente as melhores ferramentas de anonimização e as mais poderosas ferramentas de re-identificação disponíveis. Este paradoxo implica uma corrida armamentista inerente: ao utilizar LLMs para melhorar a anonimização (Operador 5 do PrivacIA), também se avança a capacidade adversarial contra a qual o framework deve proteger. A resolução pragmática adotada pelo PrivacIA é manter o LLM de anonimização local e atualizado, enquanto testa periodicamente contra LLMs comerciais como adversários.
4. **Contexto implícito:** Informações pessoais implícitas no texto sem menção explícita de entidades permanecem um desafio significativo. Técnicas de NER e regex são fundamentalmente limitadas a entidades explícitas, e mesmo a verificação por LLM local pode falhar em identificar inferências complexas baseadas em múltiplas pistas contextuais distribuídas ao longo do documento.
5. **Trade-off privacidade-utilidade:** Anonimização excessiva degrada a utilidade do documento para processamento por IA [22], enquanto anonimização insuficiente cria riscos de re-identificação. A abordagem adaptativa [27] mitiga parcialmente este problema, mas não o elimina. Os resultados de CON-QA [43] são encorajadores ao demonstrar que, em domínios específicos (contratos), a degradação pode ser mantida em níveis aceitáveis.
6. **Documentos multimodais:** Imagens, gráficos e tabelas em PDFs requerem tratamento via OCR, e PII em formato visual (assinaturas, fotos, cabeçalhos de instituições) não são cobertos pelo pipeline textual atual.
7. **Evolução contínua dos padrões:** Novos tipos de identificadores (PIX, chaves aleatórias, QR codes) exigem atualização contínua dos módulos de detecção.
8. **Custo computacional de LLMs locais:** A verificação por LLM local aumenta significativamente o tempo de processamento. LLMs quantizados (Q4/Q5) podem reduzir este custo, mas com potencial impacto na qualidade da anonimização.
9. **Falta de corpus anotado público em pt-BR:** Apesar dos avanços do LGPDBenchmark [37] e do AnonyMed-BR [10], o ecossistema de dados anotados para anonimização em português brasileiro permanece limitado em escala e diversidade de domínios.
10. **Desanonimização industrial por agentes LLM:** Os resultados de Adiwardana et al. [50] (68% recall a 90% precisão) e Moisio et al. [49] (encadeamento de pistas fracas por agentes multi-hop) demonstram que a desanonimização não é mais uma ameaça teórica, mas uma capacidade operacional acessível a qualquer adversário com acesso a LLMs comerciais. O

benchmark de [52] reforça esta preocupação ao mostrar que mesmo o anonimizador GPT-4 alcança apenas 27% de proteção efetiva. O PrivacIA aborda esta ameaça com a T10 e o RT17, mas reconhece que a corrida armamentista entre anonimizadores e desanonimizadores tende a intensificar-se à medida que agentes LLM se tornam mais capazes de raciocínio multi-hop e acesso a bases de conhecimento externas. A defesa proativa contra inferência de atributos [53] representa uma direção promissora, porém ainda em estágio inicial de validação empírica.

B. Implicações para a Prática

Os achados deste trabalho têm implicações práticas para:

Profissionais do Direito: O PrivacIA oferece uma camada de proteção entre o documento jurídico e a API de IA, permitindo o uso de ferramentas como ChatGPT e Claude para análise de petições sem expor dados de clientes. A conformidade com o Art. 42 (responsabilidade civil) é especialmente relevante para escritórios de advocacia.

Profissionais de Saúde: A integração com os achados do AnonyMed-BR [10] permite extensão para prontuários médicos, com atenção especial a dados sensíveis de Nível 3 (Art. 11 LGPD).

Organizações e DPOs: O framework fornece evidências auditáveis de conformidade (RT16), úteis em processos de prestação de contas à ANPD e em litígios envolvendo violação de dados.

Reguladores: A abordagem de “esforços razoáveis” implementada pelo PrivacIA pode servir como referência prática para a ANPD na definição de padrões técnicos de anonimização.

C. Trabalhos Futuros

1. **Fine-tuning de modelos NER** para domínios jurídico e médico brasileiros, com criação de corpus anotado público, construindo sobre os avanços do LGPDBenchmark [37] e do LeNER-Br [25];
2. **Avaliação adversarial formal** com red-teaming por especialistas e múltiplos LLMs, seguindo o protocolo ASQ-PHI [45] para geração de dados adversariais controlados;
3. **Integração com provedores de IA** via plugins (extensão VS Code, plugin navegador, integração com RAG conforme demonstrado por CON-QA [43]);
4. **Anonimização adaptativa** com otimização de prompts [27] para calibrar automaticamente o nível de anonimização;
5. **Arquitetura baseada em agentes** inspirada no AnonymAI [39] para orquestração inteligente dos módulos de detecção, classificação e substituição;
6. **Anonimização multimodal** expandindo para imagens, áudio e documentos com OCR;
7. **Certificação LGPD** com processo de avaliação para ferramentas de anonimização, em diálogo com a ANPD;
8. **Benchmark público** para anonimização de documentos em português brasileiro, expandindo o LGPDBenchmark [37] para múltiplos domínios;
9. **Estudo longitudinal** sobre a evolução da eficácia da anonimização à medida que LLMs avançam, testando a hipótese de Kalari et al. [44] sobre as limitações fundamentais da anonimização.

X. Conclusão

Este artigo investigou a research question: *Quais requisitos técnicos e jurídicos um framework de anonimização deve atender para garantir conformidade com a LGPD no contexto de uso de IA generativa?*

Para responder, propusemos o PrivacIA, um framework modular que implementa um pipeline de quatro estágios otimizado para documentos brasileiros nos domínios jurídico, médico e financeiro. A principal contribuição é sêxtupla: (1) o mapeamento sistemático de 17 artigos e disposições da LGPD para requisitos técnicos concretos, incluindo direitos do titular (Art. 18), responsabilidade civil (Art. 42) e defesa proativa contra desanonimização (Art. 46); (2) a análise adversarial expandida com 10 categorias de ameaças, incluindo correlação entre documentos, re-identificação temporal e desanonimização em larga escala por agentes LLM; (3) a integração do fluxo completo anonimização, envio à IA e re-identificação em uma ferramenta open-source; (4) um desenho experimental concreto com baselines ampliados (incluindo Look Twice [51] e pipeline de desanonimização [50]), métricas formais e protocolo de avaliação humana; (5) a contextualização do framework na literatura emergente sobre o uso dual de LLMs como anonimizadores e re-identificadores; e (6) a incorporação de evidências recentes sobre desanonimização industrial por agentes LLM [49][50], que demonstram que a ameaça atingiu escala operacional (68% recall a 90% precisão), exigindo defesas proativas e não apenas reativas.

A análise adversarial demonstra que abordagens tradicionais de anonimização (NER + regex isolados) são insuficientes contra adversários equipados com LLMs modernos [41][44] e, de forma ainda mais alarmante, contra pipelines automatizados de agentes LLM capazes de encadear pistas fracas para reconstruir identidades em escala [49][50]. Mesmo o anonimizador GPT-4 alcança apenas 27% de proteção efetiva contra re-identificação [52], evidenciando que a substituição sem validação adversarial é fundamentalmente insuficiente. O critério de “esforços razoáveis” do Art. 12 da LGPD deve ser interpretado dinamicamente, com reavaliação periódica conforme a evolução das capacidades de LLMs — uma posição reforçada pelos achados de Kalari et al. [44] sobre as limitações fundamentais da anonimização na era dos LLMs, pela análise de Weitzenboeck et al. [47] sobre a (im)possibilidade da anonimização de dados não estruturados e pelos resultados empíricos de [50] que demonstram a operacionalização desta ameaça.

O framework PrivacIA oferece uma solução prática, auditável e adversarialmente validada para profissionais que necessitam utilizar IA generativa sem comprometer direitos dos titulares de dados, contribuindo para a construção de um ecossistema de IA responsável no contexto regulatório brasileiro e para o avanço da cultura de proteção de dados no país.

Referências

- [1] M. U. Hadi et al., “A Survey on Large Language Models: Applications, Challenges, Limitations, and Practical Usage,” *TechRxiv*, 2023, doi: 10.36227/techrxiv.23589741.v1.
- [2] W. Villegas-Ch and J. García-Ortiz, “Toward a Comprehensive Framework for Ensuring Security and Privacy in Artificial Intelligence,” *Electronics*, vol. 12, no. 18, p. 3786, 2023, doi: 10.3390/electronics12183786.
- [3] K. Mishra, H. Pagare, and K. Sharma, “A hybrid rule-based NLP and machine learning approach for PII detection and anonymization in financial documents,” *Scientific Reports*, vol. 15, 2025, doi: 10.1038/s41598-025-04971-9.

- [4] Brasil, “Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD),” *Diário Oficial da União*, 2018. Disponível: https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/113709.htm
- [5] N. Carlini et al., “Extracting Training Data from Large Language Models,” in *Proc. USENIX Security Symposium*, 2021.
- [6] H. Aditya, S. Chawla, G. Dhingra, and P. Jain, “Evaluating Privacy Leakage and Memorization Attacks on Large Language Models (LLMs) in Generative AI Applications,” *JSEA*, vol. 17, no. 5, pp. 421-447, 2024, doi: 10.4236/jsea.2024.175023.
- [7] InstaTunnel, “Differential Privacy Reversal via LLM Feedback: The Silent Killer of Data Anonymization,” *Medium*, 2025. Disponível: <https://medium.com/@instatunnel/it-162aee1dbfe5>
- [8] R. Tedesco, “Privacy and security in large language models and data,” in *Large Language Models in Cybersecurity*, Elsevier, 2026, doi: 10.1016/b978-0-443-33592-1.00011-5.
- [9] Parlamento Europeu e Conselho, “Regulamento (UE) 2016/679 (GDPR),” *Jornal Oficial da União Europeia*, 2016. Disponível: <https://eur-lex.europa.eu/eli/reg/2016/679/oj>
- [10] M. Schiezaró, G. Rosa, B. A. G. Campos, and H. Pedrini, “Guardians of the data: NER and LLMs for effective medical record anonymization in Brazilian Portuguese,” *Frontiers in Public Health*, vol. 13, 2026, doi: 10.3389/fpubh.2025.1717303.
- [11] I. Karamitsos, N. Roufas, K. Al-Hussaini, and A. Kanavos, “LegNER: a domain-adapted transformer for legal named entity recognition and text anonymization,” *Frontiers in Artificial Intelligence*, vol. 8, 2025, doi: 10.3389/frai.2025.1638971.
- [12] ANPD Brasil, “Estudo Preliminar: Inteligência Artificial Generativa — Radar Tecnológico,” 2024. Disponível: <https://www.gov.br/anpd/pt-br>
- [13] Parlamento Europeu e Conselho, “Regulamento (UE) 2024/1689 — EU AI Act,” *Jornal Oficial da União Europeia*, 2024.
- [14] L. Pereira, S. Spósito, F. L. de Mendonça, and E. D. Canedo, “Privacy and Artificial Intelligence in Brazil: An Analysis of Bill 2,338/2023 and Its Complementarity with the LGPD,” in *Proc. ICEIS*, 2026, doi: 10.5220/0014730300004018.
- [15] M. Finck and F. Pallas, “They who must not be identified—distinguishing personal from non-personal data under the GDPR,” *International Data Privacy Law*, vol. 10, no. 1, pp. 11-36, 2020, doi: 10.1093/idpl/ipz026.
- [16] L. Sweeney, “k-Anonymity: A Model for Protecting Privacy,” *Int. J. Uncertainty, Fuzziness and Knowledge-Based Systems*, vol. 10, no. 5, pp. 557-570, 2002.
- [17] A. Machanavajjhala, D. Kifer, J. Gehrke, and M. Venkatasubramanian, “l-Diversity: Privacy Beyond k-Anonymity,” *ACM TKDD*, vol. 1, no. 1, 2007.
- [18] N. Li, T. Li, and S. Venkatasubramanian, “t-Closeness: Privacy Beyond k-Anonymity and l-Diversity,” in *Proc. IEEE ICDE*, 2007, pp. 106-115.
- [19] C. Dwork, “Differential Privacy,” in *Proc. ICALP*, 2006, pp. 1-12.
- [20] S. Lison et al., “Anonymise: A Tool for Multilingual Document Pseudonymisation,” *ResearchGate*, 2024, doi: 10.48550/arXiv.2405.11531.

- [21] E. S. Ruzzetti et al., “Private Memorization Editing: Turning Memorization into a Defense to Strengthen Data Privacy in LLMs,” in *Proc. ACL*, 2025, doi: 10.18653/v1/2025.acl-long.810.
- [22] T. Yang, X. Zhu, and I. Gurevych, “Robust Utility-Preserving Text Anonymization Based on Large Language Models,” *arXiv:2407.11770*, 2024.
- [23] D. Nadella, “Securing Data at Rest: Using ML-Driven PII Detection and Privacy-Enhancing Technologies,” in *Proc. IEEE ICEET*, 2024, doi: 10.1109/iceet65156.2024.10913953.
- [24] F. Souza, R. Nogueira, and R. Lotufo, “BERTimbau: Pretrained BERT Models for Brazilian Portuguese,” in *Proc. BRACIS*, 2020.
- [25] P. H. L. Luz de Araujo et al., “LeNER-Br: a Dataset for Named Entity Recognition in Brazilian Legal Text,” in *Proc. PROPOR*, 2018.
- [26] F. Albanese, P. Ronco, and N. D’Ippolito, “Anonymous-by-Construction: An LLM-Driven Framework for Privacy-Preserving Text,” *arXiv:2603.17217*, 2026.
- [27] G. Loiseau, D. Sileo, D. Riquet, M. Meyer, and M. Tommasi, “Adaptive Text Anonymization: Learning Privacy-Utility Trade-offs via Prompt Optimization,” *arXiv:2602.20743*, 2026.
- [28] A. C. R. Braz and E. D. Canedo, “Mapping LGPD Principles to Ethical Principles in the Context of Artificial Intelligence,” in *Proc. WICS*, 2025, doi: 10.5753/wics.2025.7160.
- [29] Microsoft, “Presidio — Data Protection and De-identification SDK,” GitHub, 2023. Disponível: <https://github.com/microsoft/presidio>
- [30] Explosion AI, “spaCy — Industrial-Strength Natural Language Processing,” 2024. Disponível: <https://spacy.io/>
- [31] Faker Contributors, “Faker — Python Package for Generating Fake Data,” 2024. Disponível: <https://faker.readthedocs.io/>
- [32] F. Kohlmayer et al., “ARX — Data Anonymization Tool,” 2024. Disponível: <https://arx.deidentifier.org/>
- [33] G. Feretzakis and V. S. Verykios, “Trustworthy AI: Securing Sensitive Data in Large Language Models,” *AI*, vol. 5, no. 4, p. 134, 2024, doi: 10.3390/ai5040134.
- [34] A. Bansal, “System to Redact Personal Identified Entities (PII) in Unstructured Data,” *IJARET*, vol. 11, no. 6, 2020, doi: 10.34218/ijaret.11.6.133.
- [35] J. Domingo-Ferrer, “Big Data Anonymization Requirements vs Privacy Models,” in *Proc. SECURE*, 2018, doi: 10.5220/0006830004710478.
- [36] S. Yechuri, “Enhanced Utility-Driven Data Anonymization: Leveraging AI and ML for Sensitive Data Protection,” *JAIGS*, vol. 1, no. 1, 2024, doi: 10.60087/jaigs.v1i1.229.
- [37] R. S. de Souza Filho and L. C. Ribas, “LGPDBenchmark: A Legal Text Corpus for Pseudonymization Evaluation in Brazilian Portuguese,” *Research Square*, 2025, doi: 10.21203/rs.3.rs-8309951/v1.
- [38] T. Anselmo and L. C. Ribas, “Pseudonymization in Legal Texts According to the LGPD: A Named Entity Recognition Approach,” in *Proc. Springer*, 2024, doi: 10.1007/978-3-031-79032-4_22.
- [39] L. Soares et al., “AnonymAI: Differential Privacy and Intelligent Agents for Automated Anonymization,” *Future Internet (MDPI)*, vol. 18, 2026.

- [40] LegalGuardian Authors, “LegalGuardian: A Privacy-Preserving Framework for LLMs in Legal Practice,” *arXiv*, 2025, doi: 10.48550/arxiv.2501.10915.
- [41] R. Staab et al., “Large Language Models Are Advanced Anonymizers,” *arXiv:2402.13846*, 2024.
- [42] D. Wiest et al., “LLM-Anonymizer: Local Large Language Models for Medical Document Deidentification,” *NEJM AI*, 2025, doi: 10.1056/aidbp2400537.
- [43] A. Singh et al., “CON-QA: Privacy-Preserving Question Answering in the Contract Domain Using Anonymization,” *arXiv:2509.19925*, 2025.
- [44] N. Kalari et al., “Revisiting Data Anonymization: Limitations and Challenges in the Era of Large Language Models,” *IEEE*, 2026.
- [45] W. Weatherhead et al., “ASQ-PHI: Adversarial Synthetic Data Benchmark for Clinical De-identification,” *Data in Brief*, 2026, doi: 10.1016/j.dib.2026.112586.
- [46] A. Miranda et al., “Preserving Privacy in Large Language Models: A Survey on Threats and Solutions,” *arXiv:2408.05212*, 2024.
- [47] E. M. Weitzenboeck et al., “The GDPR and Unstructured Data: Is Anonymization Possible?,” *International Data Privacy Law*, 2022, doi: 10.1093/idpl/ipac008.
- [48] W. Alghamdi, “Adaptive Differential Privacy for Clinical Large Language Models,” *Scientific Reports*, 2026, doi: 10.1038/s41598-026-45883-6.
- [49] M. Moisio et al., “From Weak Cues to Real Identities: Evaluating Inference-Driven De-Anonymization in LLM Agents,” *arXiv:2603.18382*, 2026.
- [50] D. Adiwardana et al., “Large-scale online deanonymization with LLMs,” *arXiv:2602.16800*, 2026.
- [51] Y. Wang et al., “Look Twice before You Leap: A Rational Agent Framework for Localized Adversarial Anonymization,” *arXiv:2512.06713*, 2025.
- [52] Anonymous, “Unique between the lines: benchmarking re-identification risk for text anonymization,” *OpenReview*, 2026.
- [53] Z. Chen et al., “Stop Tracking Me! Proactive Defense Against Attribute Inference Attack in LLMs,” *arXiv:2602.11528*, 2026.